SAPIENTIA ERDÉLYI MAGYAR TUDOMÁNYEGYETEM
MAROSVÁSÁRHELYI KAR
INFORMATIKA SZAK

BILLENTYŰZÉSI RITMUS ALAPÚ MÁSODLAGOS AZONOSÍTÓ MODUL PHP WEB ALKALMAZÁSOKHOZ

DIPLOMAMUNKA

Témavezető:
Dr. Szabó László-Zsolt, adjunktus

Végzős hallgató:
Ágoston István

2018

UNIVERSITATEA SAPIENTIA DIN CLUJ-NAPOCA
FACULTATEA DE ȘTIINȚE TEHNICE ȘI UMANISTE, TÎRGU-MUREȘ
SPECIALIZAREA INFORMATICĂ

MODUL DE AUTENTIFICARE SECUNDARĂ PENTRU APLICAȚII WEB PHP PRIN DINAMICA TASTĂRII

PROIECT DE DIPLOMĂ

Coordonator științific:
Dr. Szabó László-Zsolt, lector

Absolvent:
Ágoston István

2018

SAPIENTIA UNIVERSITY

FACULTY OF TECHNICAL AND HUMAN SCIENCES, TÎRGU-MURES

COMPUTER SCIENCE SPECIALIZATION

KEYSTROKE DYNAMICS BASED SECONDARY AUTHENTICATION MODULE FOR PHP WEB APPLICATIONS

DIPLOMA THESIS

Advisor:
Dr. Szabó László-Zsolt, adjunct

Student:
Ágoston István

2018

Abstract

The development of online browsing and the wide range of online administration is motivating us to create more and more accounts. Doing so, our information is being stored and we get access to number of functions. To prevent others from accessing this information, diverse sorts of authentication methods have been developed, for the safety of users. Despite this, if an unauthorized person gains access to our online account, not only our user information, but our goods may be endangered, too.

The purpose of my thesis is creating a secondary authentication system for web applications, which would improve on authentication via username-password pair. It is realized by comparing the entered characters press and release pattern with some previously gained patterns. The application have been created in a PHP framework called Laravel, and the data is stored in the Firebase real time database.

During work we have created a data collecting interface, where the participants of our experiment may provide a dataset by typing some text. By this, we gained an own dataset, and we may execute experiments on them, in hope of useful information for future works. Besides that, we also implement an authentication interface, where we may test the application in real-life situations.

During the tests with our data, we reproduced results known from the literature on different test cases (9-10% EER – Equal Error Rate). Because we make tests on both username, password and full name, we realized a fusion procedure, which provided a better EER.

Keywords: authentication by keystroke dynamics, secondary authentication, Laravel, web security

Abstract

Răspândirea rapidă a navigării online, și administrarea online care devine tot mai extinsă, ne inspiră să ne creem conturi de utilizator. Prin acestea, datele noastre sunt păstrate în siguranță și ajungem la mai multe funcțiuni pe o anumită pagină. Pentru ca alte persoane să nu ajungă în posesia acestor date, s-au creat diferite metode de identificare în vederea protecției utilizatorilor. Cu toate acestea, dacă o persoană neautorizată ne accesează propriul cont online, nu doar că ajunge în posesia datelor noastre de utilizator, ci poate însemna și o amenințare asupra bunurilor noastre materiale.

Scopul lucrării mele de licență este crearea unui sistem secundar de validare pentru aplicațiile web, care crește siguranța autentificării cu nume utilizator și parolă. Acest lucru îl va realiza prin compararea modelului de tastare a caracterelor scrise cu cele scrise mai înainte. Am creat aplicația într-un sistem PHP, si anume Laravel, și am folosit Firebase pentru stocarea datelor în timp real.

Rezultatul este o interfață de colectare, unde participanții la experiment au oferit un set de date cu introducerea a câteva texte. Prin acesta obținem un set de date propriu și putem face experimente pe el, prin care ne sunt oferite rezultate utile pentru efectuarea unor cercetări în viitor. Pe lângă asta, am implementat și o interfață de identificare unde putem testa aplicația și în situații real.

Cuvinte cheie: recunoaștere pe baza tastării, validare secundară, Laravel, web, siguranță

Kivonat

Az internetes böngészés rohamos terjedése és az egyre tágabb körű online ügyintézés ösztönöz, hogy felhasználói fiókokat hozzunk létre. Ezek által adataink biztonságosan eltárolódnak és több funkcióhoz is jutunk egy adott oldalon. Ahhoz, hogy ezekhez az adatokhoz más ne férhessen hozzá, különféle azonosítási módszereket dolgoztak ki a felhasználók védelme érdekében. Ennek ellenére, ha egy illetéktelen személy belépést nyer saját online fiókunkba, akkor nem csak felhasználói adatainkat, de akár anyagi javainkat is veszélyeztetheti.

Diplomamunkám célja egy olyan másodlagos hitelesítő rendszer létrehozása webes alkalmazások számára, amely a felhasználónév-jelszó párossal való beléptetés biztonságát növeli. Ezt úgy valósítja meg, hogy összehasonlítja a felhasználó által beírt karakterek leütési mintáját a már korábban bevitt mintákkal. Az alkalmazást egy PHP keretrendszerben, Laravelben készítettük el és az adatok tárolására a Firebase adatbázist használtuk.

A munka folyamán megvalósítottunk egy adatgyűjtő felület, ahol a kísérletben résztvevők néhány szöveg begépelésével egy billentyűzési ritmus adathalmazt szolgáltatnak. Ez által saját adathalmazra teszünk szert és kísérleteket hajthatunk rajtuk végre, amelyek hasznos eredményeket szolgáltathatnak a jövőbeli kutatásokra nézve. Emellett egy azonosító felületet is implementáltunk, ahol le tudjuk tesztelni éles helyzetekben is az alkalmazást.

A saját gyűjtési adatok tesztelésénél a szakirodalomból ismert eredményeket kaptunk különböző tesztesetekre (9-10% EER - egyenlő hibaarány). Mivel jelszón kívül felhasználó nevet is teszteltünk, megvalósítottunk egy fúziós eljárást, ami jobb EER értékeket ad.

Kulcsszavak: billentyűzés alapú felismerés, másodlagos hitelesítés, Laravel, webes biztoság

Tartalomjegyzék

Ábrák, táblázatok jegyzéke

1. Bevezető

Az internet rohamos fejlődése által egyre több olyan tevékenységet vagyunk képesek lebonyolítani otthon, ami személyes jelenlétet igényelt volna évekkel ezelőtt. Manapság a legújabb okos telefonok megvásárlásától a banki átutalásokig bármit képesek vagyunk pár mozdulattal lebonyolítani és ezzel arányosan hatalmasra nőtt a felhasználói fiókjainknak az értéke is. Bárki, aki az adatainknak, vagy éppen azonosító tárgyainknak (pl. bankkártya, beléptető tóken) a tulajdonában van, képes arra, hogy hozzáférjen a személyes adatainkhoz, vagy akár az anyagi értékeinkhez is.

Tegyük fel, hogy nem biztonságosan kezeltük egy online banki alkalmazásnál használt fiókunkat és a belépési adatainkat megszerezte egy harmadik fél, akinek szándéka ezt a lehetőséget kihasználni. Ilyen esetben segít egy másodlagos hitelesítő rendszer, ami képes a az esetleges betolakodók detektálására. A rendszer észleli azt, hogy a belépett személynek egyes tulajdonságai nem egyeznek meg a regisztrált felhasználóéval, ezért jelzést küld, és további megerősítést kér. Amennyiben a megerősítés nem megy végbe, a rendszer elkönyvelheti, hogy feltörés ment végbe és segítséget tud nyújtani a felhasználónak a további biztonsági lépések megtételéhez.

Egy ilyen rendszernél például ajánlatos viselkedési biometrián alapuló eszközökkel ellenőrizni, hogy valódi-e a felhasználó. Ezek az eszközök képesek arra, hogy a felhasználót a vele született, egyedi viselkedés mintái és mikro-mozzanatai alapján összehasonlítsák a korábbi belépéseihez és megállapítsák, hogy mekkora hasonlóság mérhető nála.

Általában egy ilyen rendszernél nem csak egyfajta viselkedést ellenőriznek, ugyanis a viselkedési biometrián alapuló hitelesítők nem képesek száz százalékos eredményt garantálni és megeshet, hogy a utánzó felhasználót beengedik, vagy éppen a valós felhasználót kizárják. Ennek elkerülésére a rendszer több viselkedést is kell, hogy figyeljen és az egyes tulajdonságok (billentyűzés, egérmozgás, szóhasználat a leírt szövegekben, stb.) mind visszaadnak egy szavazatot, amit összegezve megkapjuk, hogy mi a teendő az adott felhasználóval.

A fiókunk biztonsága érdekében tehát érdemes minél jobban megerősíteni a védelmet és erre egy módszer a billentyűzési ritmus figyelése. A felhasználónak tudnia nem kell róla, mert a háttérben működik. Emellett már egyre jobb és jobb eredményeket érnek el ilyen téren, tehát valószínű, hogy hamarosan egyre több oldalon lesz lehetőség ez a fajta másodlagos azonosítás is.

2. A projekt célja

Az első fejezetben említett billentyűzés alapú azonosítási modul megvalósítása képezi a projekt fő célját. Ez magába foglalja egy minta-gyűjtő rendszer létrehozását, mely segítségével a további kísérletekhez tudunk tanító és tesztelő adathalmazokat biztosítani, valamint egy azonosító rendszer létrehozását, ami segítségével a felhasználót egy második biztonsági réteggel is meg tudjuk védeni.

Jelenleg számos kísérlet folyik jobb és jobb eredményekért a billentyűzési ritmus alapú felismeréssel kapcsolatosan. Már a telegráf korában felfigyeltek az emberek a tényre, hogy be tudják egymást azonosítani a beütési ritmusuk alapján. Ez többnyire annak is köszönhet, hogy hogy az emberi agynak ugyanazok a neuro-fiziológiai részei kerülnek használatba gépeléskor, mint amik az aláírások esetében is. Bár egyre több kísérlet folyik ilyen irányban, teljes pontosságú megoldást még nem találtak és viszonylag kevés rendszernél alkalmazzák a módszert.

Az alkalmazás célközönsége az érzékeny adatokat kezelő alkalmazások köre, mivel ilyen esetekben kifejezetten fontos az, hogy az belépett felhasználó az legyen, aki a tulajdonosa a fióknak.

Megvalósítás céljából a PHP egyik keretrendszerét, a Laravelt használtam. A választás azért esett a Laravel-re, mert számos ponton megkönnyíti a rendszer implementációját és amennyiben más PHP alapú rendszerbe szeretnénk a modult integrálni, kevés átalakítással képesek vagyunk rá. Az alkalmazás egyaránt képes gyűjteni adatokat a valós felhasználótól, valamint külön oldal van létre hozva arra is, hogy pár, a kísérletbe beavatott személy próbáljon belépni a tesztelt felhasználó adataival. Ezeket a belépési kísérleteket szintén elmentjük. A teljes adatbázis JSON formátumban van eltárolva a Firebase valós idejű adatbázisban. Egyes számításokhoz a kísérletek folyamán - amiket Matlabban végeztünk - létrehoztunk egy átalakítót is, ami a JSON formátumban megadott adatainkat csv formátumba konvertálja.

Egy másik célja az államvizsga munkámnak, hogy minél hatékonyabb algoritmust, illetve jellemző kiemelő módszert találjak saját kísérleteket is bevonva. Emellett az alkalmazást működővé tenni mobil eszközökön illetve táblagépeken is.

3. Bibliográfiai tanulmány

A gyűjteni kívánt adatok milyenségének megfogalmazásában az [1] cikk fontos szerepet játszott. Ez bemutat egy adatgyűjtési és kísérleti fázist. Az érdekessége abban nyilvánul meg, hogy az adathalmazból a jelszavat teljesen kihagyják, és e helyett inkább a felhasználók személyes adatait, mint név, személyi szám, nemzetiség, e-mail cím, kell, hogy begépelje. Azt feltételezték, hogy a személyes információ begépelésével jobb eredményt érnek el. Szintén itt van bemutatva egy módosított változata a Manhattan Scaled algoritmusnak, melynél a felhasználók 25% esetében az EER 0%-ra esett, és a többi mérésnél is jó eredményt értek el vele.

A Killourhy által végzett munkásságot leíró cikk [2] szintén algoritmusok összehasonlítására fókuszált amellett, hogy bemutassa saját adatgyűjtését. Az adathalmaz 51 felhasználó billentyűzési adataiból lett létrehozva, 400 mintát tartalmazva minden felhasználó esetében, valamint mivel a beírt jelszó ugyanaz, ezért külön imposztor adathalmaz is van minden felhasználó számára. A kísérleti eredmények 9.6% és 10.2%-os EER-t mutattak legjobb esetben, fúzió használata nélkül.

[3] cikkben egy összefoglaló tanulmányt olvashatunk, melyben le van írva a 2013-ig publikált eredmények nagy része. Megismerhetjük általa a di-gráf valamint az n-gráf fogalmát, és a többi tulajdonság kiemelési módszert. Emellett bemutatja, hogy az akkor elért eredmények között is már volt akár 1.401% mértékű egyenlőségi hibaarány, kevert megoldásokkal, valamint 0% közeli is többrétegű perceptronokkal és nagy mennyiségű adatokkal.

A *„Handbook of multibiometrics”* [5] könyvben rálátást nyerünk a biometriai eszközök közti fúzióra, mely segítségével akár több, különböző módon osztályozott mezőt képesek vagyunk egyként azonosítani, és így jobb eredményt elérni, mintha külön vettük volna őket.

[6] tézisben a küszöbérték meghatározásának a módszerét ismertetik, egyosztályos osztályozók esetében. Ez a mi esetünkben is hasznos, mivel valós rendszer esetében nem rendelkezünk imposztor mintákkal.

A Manhattan Scaled távolság alapú algoritmusról a [7] cikkben részletes bemutatást kaphatunk.

[8] cikk által más megközelítésből láthatjuk a Manhattan Scaled és Mahalanobi algoritmusokat, valamint a tulajdonságok közti korrelációnak a hatásaival is szembesítődünk.

4. Elméleti megalapozás

4.1 A biometrián alapuló azonosítás áttekintése

Az éppen bejelentkező felhasználóról eldönteni, hogy tényleg ő birtokolja-e az adott fiókot, több módon is lehetséges. Az azonosítási módszereket az alábbi három kategóriába soroljuk:

1. Tudás alapú azonosítás - Jelszó, minta illetve kérdés alapú ellenőrzések tartoznak ide. Legnagyobb előnyük hogy könnyű őket implementálni, míg hátrányuk, hogy el lehet őket felejteni, vagy éppen fel is törhetik pár algoritmus segítségével.
2. Token alapú azonosítás - Általában egy tárgy segítségével azonosítsák a felhasználót, ami csak az ő birtokában lehet. Ezt feltörni nehezebb és általában az elkészítése olcsó, de könnyű elveszíteni. Ide tartoznak a bankkártyák és a beléptető csipogók (például a Sapientia marosvásárhelyi székhelyének a bentlakásánál).
3. Biometrián alapuló azonosítás – A felhasználónak egy adott viselkedését vagy vele született jellemzőjét vizsgáljuk az azonosítás során. Két fajtája lehet:
    a. fiziológiai, amelyet nehéz hamisítani és magas pontossággal rendelkezik, mind például az ujjlenyomat vizsgálása vagy a retina ellenőrzése. Ezek a rendszerek viszont költségesek és mivel a felhasználó vele született fizikai tulajdonságát nézi, amennyiben egyszer sikerül megszereznie egy harmadik félnek a mintát, a felhasználó többé nem használhatja az adott módszert.
    b. viselkedési, melynél azt nézzük, hogy a felhasználó „hogyan” csinál valamit, nem pedig azt hogy mit csinál. Ilyen azonosításokat végezhetünk az egérmozgás, járás, hang, billentyű leütési ritmus és még sok egyéb egyedi mintát alkotó viselkedés elemzésével. Ezek a rendszerek általában nem biztosítanak teljes pontosságot, mivel megeshet, hogy kizárják a valódi felhasználót, vagy éppen beengedik az utánzót.

Bár a viselkedési biometrián alapuló rendszerek képesek arra, hogy egymagukban, viszonylag magas pontossággal azonosítsák a felhasználót, egy ilyen rendszer önmagában ma még nem elég biztonságos. Ezért is az alkalmazásnál ez a fajta hitelesítés nem veszi át a felhasználónév-jelszó páros szerepét, hanem az azonosított felhasználókat ellenőrzi le, hogy tényleg ők-e azok, akik eddig is folyamatosan bejelentkeztek.

Egy másik fontos része a billentyűzés alapú hitelesítésnek, mint bármely más viselkedésen alapuló biometriai hitelesítőnek, hogy egymagában mivel téves adatot adhat, több ilyen ellenőrző modullal együtt képesek valós képet alkotni a felhasználó kilétéről. Például a billentyűzés mellett még lehet nézni az egér mozgását is. Ezért ajánlatos az alkalmazásban megírt azonosító modult egy szavazó komponensként alkalmazni az ellenőrzés során.

4.2 Billentyűzési biometria webes alkalmazásban

Az dolgozatmunkám egy webes alkalmazásra épül, mivel sokkal könnyebben meg lehet valósítani az adatgyűjtést, ha egy szerveren rajta van az oldal és egyidejűleg korlátlan számú felhasználó írhatja be az adatokat. Ennek ellenére a felhasználónak lehetősége van arra, hogy ha nincs felügyelve, akkor egy rövid időre megszakítsa a gépelést és ez elrontja az adott mintát. Emiatt párhuzamosan gyűjtöttem felügyelet nélküli beviteleket és általam felügyelteket is.

Az alkalmazás gyűjtésénél a JavaScriptben megírt JQuery könyvtár függvényeit használtam, melyek által le lehet kérni az adott billentyűnek a lenyomási és felengedési idejében kapott időbélyeget. Ezeket egy rejtett mezőben tárolva tovább lehet küldeni az űrlap beküldése során és a szerver feldolgozza, majd tárolja őket.

Egy másik előnye a webes alkalmazásoknak ilyen téren, hogy kevés módosítással képesek vagyunk arra, hogy a számítógép/laptop billentyűzetei mellett a rendszert működésre bírjuk okos telefonokon és táblagépeken is.

4.2.1 Bemeneti mezők megválasztása

Tekintsünk most el pár pillanatra a programozás résztől és nézzünk rá a problémára úgy, hogy közben próbáljuk az emberi viselkedésnek a jellemzőit felhasználni.

Már számos adathalmazt hoztak létre erre a biometriára, ezek közül hármat használtunk algoritmusok kipróbálására. Ezek különböző szempont szerinti gyűjtések, nem csak a beléptető jelszót, hanem felhasználó nevet és más adatok gépelését is tartalmazzák.

A három billentyűzés dinamikai adatbázis a következő:

- ATVS-Keystroke database [1] – 63 felhasználónak 12 valós és 12 imposztor általi belépése van tárolva. Minden belépés során a felhasználók a személyes adataikat adták meg, amik a vezetéknév, keresztnév, e-mail cím, nemzetiség és személyi igazolvány szám. Két szesszióban folyt le a valós felhasználótól az adatgyűjtés, szessziónként 6 belépéssel. Az adathalmaz előnye, hogy a felhasználó egy olyan szöveget kell, hogy beírjon, amit már jól ismer és ezért összefüggőbbek lesznek a mintái.
- CMU database [2] – 51 felhasználó 8 szesszióban adta le az adatait és két szesszió között legalább egy nap telt el. Ennél az adathalmaznál a felhasználók csak egy jelszót gépeltek be, ami előre meghatározott és közös volt és tartalmaz kis- és nagybetűt, speciális karaktert valamint számot. Az adathalmaz előnye, hogy nem volt szűkség külön imposztorokra, mert mindenki ugyanazt a jelszót ütötte be.
- GREYC database [9] – A kiadott cikk alapján 83 felhasználótól gyűjtöttek adatokat. Ezen adatoknak a mennyisége nem egyezett teljesen, mivel a résztvevők jóakaratától függött a bevitt adatok mennyisége. Összesen 5439 mintát gyűjtöttek. Ez az adathalmaz hasonlít az általunk gyűjtöttre, mivel a jelszó mellett a felhasználó nevet is rögzítették.

Ismerve a fent említett adathalmazokat, olyan bemeneti mezőket választottunk, amik ötvözik ezeknek a tulajdonságait és általuk olyan kísérleteket hajthatunk végre, amiket külön a két adathalmazon nem tehettünk volna. Ehhez az első mezőnek a *felhasználónevet*, a

másodiknak a személy a *valódi nevét*, míg a harmadik mezőnek egy *training password* (saját választott jelszó) nevű adatot kellett tartalmaznia. Ez utóbbi kötelező módon kell tartalmazzon kis- és nagybetűt, számot és speciális karaktert.

A gyűjtés során az első tíz minta kitörlésre kerül, amennyiben a beütött billentyű leütési-felengedési minták közül nincs legalább hat olyan, amely egyenlő hosszúságú. Ha ez az érték hat és tíz között van, akkor a nem ide tartozó minták törlésre kerülnek. Tíz minta után a felhasználó figyelmeztetve lesz, és nem tárolódik a bevitele, ha nem egyezik a hosszúsága az eddigi leütési adatokéval. Ez által az adatbázisban eltárolt minták alkalmasabbak lesznek a tanításra.

A felmerült kérdések a következők voltak: Ha a legszemélyesebb a felhasználónév akkor az is lesz a leghatékonyabb azonosításnál? Amennyiben igen, a jelszó, amit nem látunk milyen mértékben lesz kevésbé hasznos az azonosításnál, mint a másik két mező. Ezeknek a megválaszolását a 8.3-as szekcióban lehet megtalálni a többi kísérleti eredmény mellett.

4.2.2 Jellemzők kiemelése

Az adatok bevitele után következik a rendszer tanításának első része, ami a jellemzők kiemeléséből áll.

Amikor az adatok megérkeznek a szerverre, még nyers formában vannak, és úgy lehet őket kezelni, mint egy lista időbélyeg párosokból. Ezeket az adatokat nem lehetne felhasználni azonosításra, mert az időbélyegek folyamatosan változnak. Ezért a beérkező billentyűk leütési és felengedési időpontjait az őket követő billentyű leütési időiből kivonjuk. Ez által egy úgynevezett di-gráfot hozunk létre, mert kettőnként csoportosítva nyerjük ki az adatokat, amiket felhasználunk a minta elkészítésére, ami által később a felhasználót tudjuk azonosítani.

A tulajdonságok, amiket jelenleg kinyerünk a következők:

- Két egymás utáni leütés közti idő (DD = Down-Down)
- Két egymás utáni felengedés közti idő (UU = Up-Up)
- Az egyik billentyű leütése és a rákövetkező felengedése közti idő (DU = Down-Up)
- Az egyik billentyű felengedése és a rákövetkező leütése közti idő (UD = Up-Down)
- Az egyik billentyű lenyomása és felengedése között eltelt idő (H = Hold)

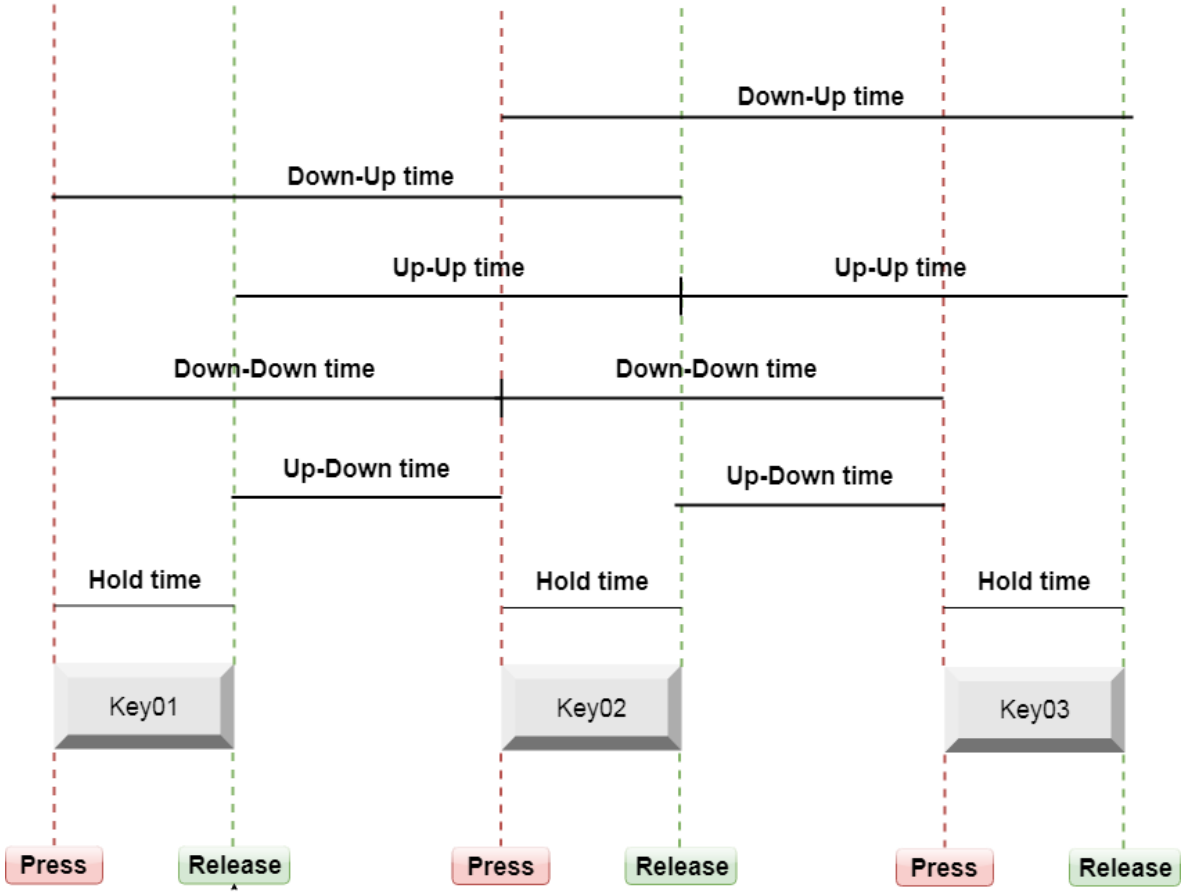

4.1. ábra - A kinyerhető tulajdonságok di-gráf esetében

Ezeket a tulajdonságokat még kibővíthetjük, hogy hármanként is nézze az időzítéseket, viszont ez az információ ugyanaz, mintha összegeznénk két di-gráf elemet, ezért nem is emeltem ki több jellemzőt.

4.2.3 Az egyenlő hibaarány

A fent említett finomított adatokat átadhatjuk egy algoritmusnak, ami a szívét fogja képezni a rendszerünknek. Egy jó algoritmus nagyságrendekkel növelheti az elért eredményt, ami alatt minél több elfogadott valódi felhasználót és elutasított imposztort értünk. Fontos, hogy az algoritmusok teljesítményét tudjuk összemérni, erre az egyenlő hibaarányt (EER = Equal Error Rate) használjuk [10, 11].

Minden kiértékelt bejelentkezési próbálkozás kap egy pontszámot (score), amiről rendszer vágáspont alapján eldönti, hogy valós felhasználónak könyveli-e el az aktuálisat. Az EER-t két tényező határozza meg: a hibásan elfogadott imposztorok aránya és a hibásan elutasított valós felhasználóké. Az a működési vágáspont, ahol ez a két hibaarány megegyezik, ott található az EER. Ezt legegyszerűbben úgy tudjuk vizualizálni, ha az adott belépési kísérletek során keletkezett hibákat ábrázoljuk az általuk szerzett pontszám (score) függvényében. Ezt elvégezve a valós és hamis felhasználókra ugyanazon az ábrán két görbét kapunk, melyeknek a metszéspontja adja az egyenlő hibaarányt.

Egy másik módszer erre a tévesen elfogadott felhasználók ábrázolása a tévesen elutasítottak függvényében. Ahol a két hibaarány megegyezik, ott található az EER.

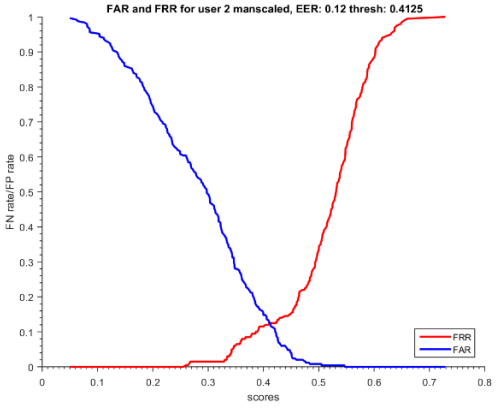

4.2. ábra -
A két görbe metszéspontjánál van az EER, ha ott helyezzük el
a metszéspontot ugyanannyit fog hibázni a valódi és utánzó felhasználóknál is.

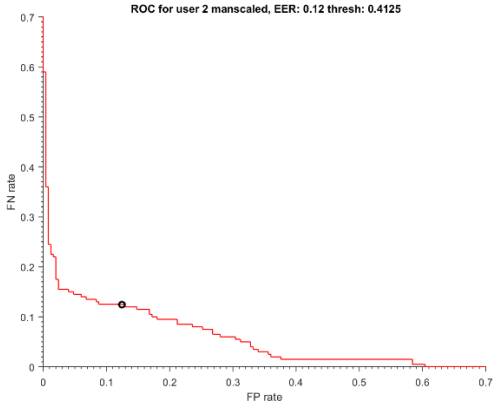

4.3. ábra -
Az egyenlő hibaarány az első szögfelezőn,
a False Positive (FAR) és False Negative (FRR) arányok alapján felírva.

Minél kisebb az EER értéke, annál jobban működhet egy beléptető rendszer.

Mikor küszöbértéket, vagy más néven vágáspontot választunk, egy olyan függőleges egyenest helyezünk el a grafikonon, ami vagy az EER ponton helyezkedik el, vagy abban az irányban mozog, amerre több hamis felhasználót ki tud zárni. Minden következő belépési kísérlet pontszáma akkor lesz elfogadva, ha meghaladja ezt az értéket. Ez lehet minden felhasználóra egy globális érték, vagy felhasználónként váltakozó.

Valós rendszereknél nem áll rendelkezésre imposztor adathalmaz, ezért a vágáspontot más módon kell, hogy beállítsuk. Erre az egyik megoldás az, hogy kizárjuk a felhasználó mintáinak leggyengébb 10 százalékát. Ezzel általában elég magasra tudjuk helyezni a vágáspontot ahhoz, hogy kizárjuk a lehetséges imposztorok nagy részét.

A következő ábrán egy felhasználó pontszámai láthatóak a Manhattan Scaled osztályozás után. Emellett ábrázolva van a vágási pont, amelynél a felhasználó adatainak a 10%-a van kizárva. Tisztán látszik, hogy a megmaradt minták sokkal közelebb vannak egymáshoz, mint a kivágottak, és ezért nagy valószínűséggel egy ilyen vágással a felhasználót helyesen fogja az algoritmus osztályozni.

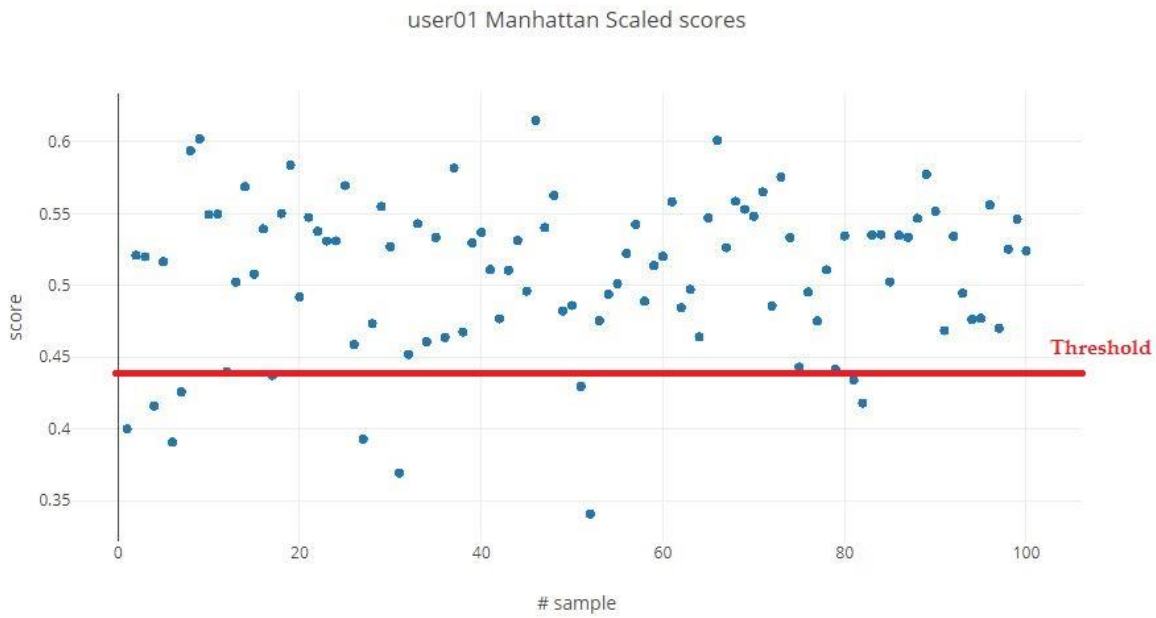

4.4. ábra - A felhasználó mintái az elért pontszám függvényében ábrázolva, a vágási pont az első 10%-ot zárja ki

4.2.4 Felhasznált algoritmusok

A következőben tárgyalt algoritmusokat először Matlab alatt teszteltük le a CMU [2] adathalmazon. Tesztelés után integráltuk az algoritmusokat a webes alkalmazásunkba is, megvalósítva azokat PHP nyelven.

4.2.4.1 Manhattan scaled

Az első algoritmus, amit kipróbáltunk, mivel egyszerűsége ellenére az egy nagyon jó eredményt ad az eddigi felmérések szerint [3]. Az említett adathalmazon tesztelve 9% EER-t kaptunk, amire a vágáspont 0.047 volt. Az algoritmus a tulajdonságok közti távolságon alapszik [4], és egy átlagolásból, valamint egy standard eltérés számolásból áll.

Első lépésként nyers adatokból kinyert tulajdonságokat (DD, UU, DU, UD, H) sorra átlagoljuk a következő képlet szerint:

$$\mu_i = \frac{1}{n}\sum_{j=1}^{n} feat(i,j) \qquad (1)$$

(1) Ahol μ_i az i. tulajdonság átlagát, n a minták számát,
és a $feat(i,j)$ az i. tulajdonság j. mintáját jelenti.

Eredményképpen egy vektort kapunk, ami sorra tartalmazza az összes leütött karakter tulajdonságainak az átlagát. Ez után standard eltérést számolunk a következőképpen:

$$\sigma_i = \frac{1}{(n-1)} \sum_{j=1}^{n} |feat(i,j) - \mu_i| \qquad (2)$$

(2) Ahol σ_i az i. tulajdonság standard eltérését, n a minták számát, és a $feat(i,j)$ az i. tulajdonság j. mintáját jelenti, valamint μ_i az i. tulajdonság átlagát.

Ez szintén egy vektort fog adni, ami a tulajdonságok eltérését mutatja az átlagtól. Ezt az értéket a pontosabb eredmény érdekében minden tulajdonságnál leskáláztuk $\frac{1}{(n-1)}$ –el. Az átlag és standard eltérés segítségével már ki tudjuk számolni egy megadott minta pontosságát, ami egy pontszám lesz. Hogy a pontszámot megkapjuk, a következő képletet alkalmaztuk:

$$D = \sum_{i=1}^{n} \frac{abs(feat(i) - \mu_i)}{\sigma_i} \qquad (3)$$

Ahol D a végső pontszámot jelenti. A fenti képlet alapján minél közelebb van egy minta, annál kisebb lesz a végső pontszám. Hogy 0 és 1 értékek közé skálázzuk, és megfordítsuk a pontszám növekedését, hogy a közeli minták nagyobb pontokat adjanak, a (4) képletet használtuk:

$$D = \frac{1}{1+D} \qquad (4)$$

4.2.5 Detektáló algoritmusok kimenetének fúziója

A biometriai eszközök esetében, amennyiben több tulajdonságot vizsgálunk egyszerre, ajánlott a kimeneteket valamilyen módon fuzionálni, mivel így jobban tudja a rendszer azonosítani a felhasználót, mint ahogy egyenként tudná a kimenetek alapján. Fúziót több módon is el végbe lehet vinni, mi kettőt próbáltunk ki ezek közül.

Az első módszer az algoritmusok kimenetén kapott pontszámok (score) fúziója, amire több matematikai módszer létezik [5]. Ilyen módszerek például:

- Középérték alapú fúzió (mean rule): a kapott pontszámokat átlagoljuk, majd ezt az értéket vizsgáljuk meg, hogy egy adott vágáspont felett van-e
- Szorzás alapú fúzió: Az eredményeket összeszorozzuk, és a kapott értéket vizsgáljuk, hogy a vágáspont felett van-e.

Egy másik módszer a jellemzők egy vektorban való elhelyezése, majd ezeknek a vektornak az osztályozása (jellemző fúzió).

A különböző kimeneteken alkalmazott algoritmus nem szükséges, hogy ugyanaz legyen, de minél jobb eredményt ér el egy algoritmus annál jobb lesz a fúzió is.

A mi esetünkben elemezhetjük külön a jelszót, személy és login nevet, és utána elvégezhetjük a kapott pontszámok fúzióját. Mivel a pontszámokat ugyanolyan jellemzőkből és ugyanolyan módszerekkel számoljuk, nincs szükség ezeknek az utófeldolgozására (normalizálás), ami sok fúziós eljárás esetében megegyezik.

5. A rendszer specifikáció

5.1 Követelmény specifikáció

5.1.1 Rövid áttekintés

A projekt célja egy olyan webes alkalmazás létrehozása, ami képes egy felhasználót hitelesíteni a bejelentkezési mezőkbe írt karakterek leütési ritmusa alapján. A hitelesítés mellett egy olyan lehetőséggel is kell, hogy rendelkezzen az alkalmazás, mely biztosít egy könnyen kezelhető adatgyűjtő felületet. A weboldal külsejénél fontos az esztétikus megszerkesztés, valamint a dinamikus navigálási lehetőség.

A projekt két részre bontható: először el kell készíteni a bejelentkezési felületet, majd a JavaScript gyűjtőt, ami által kinyerjük a felhasználó billentyű leütési időbélyegjeit.

5.1.2 Áttekintés

5.1.2.1 Funkcionalitás

A funkcionalitások a bejelentkezés illetve a tanítás köré csoportosulnak leginkább. Emellett fontos, hogy a felhasználó tudjon regisztrálni az oldalra, az elfelejtett jelszavát tudja újra beállítani e-mail cím által, valamint tudja megtekinteni tanítás esetében a saját folyamat állapotát.

A projektre vonatkozó funkcionalitások listája a következő:

- Regisztrálási funkció
  - A szükséges adatok megadásával felhasználói fiók létrehozása
- Bejelentkezési funkció
  - Valós felhasználónév-jelszó kombinációval belépés a tanító oldalra
  - Tesztelés esetében, ha a bejelentkező személy átmegy a másodlagos ellenőrzésen is, megjeleníteni, hogy sikeresen bejelentkezett
- Jelszó újraállítási funkció
  - A felhasználó az e-mail címét megadva egy link által újra tudja állítani a bejelentkező jelszavát
- Tanítási funkció
  - A felhasználó beírt adatainak és rögzített billentyűzési adatainak a lementése, amennyiben azok valósnak bizonyulnak
  - A ritmust lehetségesen elrontó karakterek letiltása vagy figyelmen kívül hagyása, helyzettől függően
  - Letiltott karakterek esetén hibaüzenet megjelenítése
- Folyamat megtekintési funkció
  - A felhasználó kell, hogy lássa, hány helyes mintát küldött be, mennyi kell egy szesszió befejezéséhez, és hány szessziót vitt végig
- Nyelvi funkció
  - Angol és magyar nyelvű felület
- Segítő funkció

- A választott nyelven visszaküldött üzenet érvénytelen adatok esetén
- Leírása a kísérletnek, a letiltott és ignorált karaktereknek, valamint az egyéb lehetséges félreértések tisztázása, mind például a tanító jelszó és a bejelentkezési jelszó közti különbség
- Megjelenítése tanító módban a beírandó adatoknak

5.1.2.2 Felhasználói osztályok és karakterisztikái

Figyelembe véve, hogy a felhasználók lehetnek tesztelők, vagy a gyűjtésben résztvevők, akik a tanító halmazt bővítik, a következő két csoportba sorolhatjuk őket:

- Tesztelő felhasználók
    - Leginkább használt funkcionalitások, sorrendben:
        - Regisztrálási funkció
        - Bejelentkezési funkció
        - Segítő funkció
        - Jelszó újraállítási funkció
        - Nyelvi funkció
- Tanító felhasználók
    - Leginkább használt funkcionalitások, sorrendben:
        - Tanítási funkció
        - Bejelentkezési funkció
        - Regisztrálási funkció
        - Segítő funkció
        - Folyamat megtekintési funkció
        - Jelszó újraállítási funkció
        - Nyelvi funkció

5.1.2.3 Működési környezet

Az alkalmazás egy internetes böngésző segítségével érhető el a kliens számára.

5.1.2.4 Felhasználói segédletek

A segítő funkció által a felhasználó rálátást nyer arra, milyen lehetőségei és megkötései vannak az oldal használata során. A regisztrálás nézeten belül specifikálva van, hogy milyen karaktereket használhat a felhasználó egyes mezőknél, valamint tisztázva vannak a mezők jelentései.

A tanító oldalon minden bejelentkezés során megjelenik egy jelzés, ami figyelmezteti a felhasználót arra, milyen karaktereket üthet le, valamint milyen megszorításokhoz kell, hogy tartsa magát az adatbevitel alatt illetve milyen segítséget nyújt az oldal. Az említett oldalon szintén lehetősége van arra a felhasználónak, hogy megtekintse a beírandó adatokat.

5.1.2.5 Megszorítások és függőségek

Az alkalmazás használatához első sorban az internetes kapcsolat elengedhetetlen.

Ezen kívül ajánlott minél újabb böngészőt használni. A böngészőnél be kell, hogy legyen kapcsolva a JavaScript, különben sem a billentyű leütési időbélyegek lekérése és továbbküldése, sem a többi JavaScript alapú funkció nem lesz elérhető.

5.1.3 Rendszer követelmények

Az alkalmazást egy szerverre kell feltölteni, hogy elérhető legyen az interneten. Szükséges egy web szerver, ajánlott az Apache. A Laravel 5.5 verziója igényeli a PHP 7.2 verzióját, valamint a Composert. Adatbázis konfigurációra nincs szűkség, mivel az összeköttetés a kulcs segítségével megoldódik.

5.1.4 Funkcionális követelmények

5.1. Táblázat - Regisztrálási funkció

Regisztrálási Funkció	
Leírás	A szükséges adatok megadásával felhasználói fiók létrehozása
Prioritás	Nagyon fontos
Kiváltás	1. A felhasználó a bejelentkezési oldalon rákattint a *Fiók regisztrálása* linkre.
Funkcionális követelmény	A regisztrációs oldalra való navigálás után a felhasználó ki kell, hogy töltse a következő mezőket: • Teljes név – szöveg, legalább 8 karakter • Életkor – szám 10 és 120 között • Felhasználónév – szöveg, legalább 8 karakter • E-mail cím – valós e-mail cím formátum • Tanítandó jelszó – ezt fogja a felhasználó a többször bevinni, legalább 8 karakteres szöveg, mely tartalmaz kis- és nagybetűt, számot és speciális karaktert • Nemzetiség – legördülő menü, lehet: Román, Magyar, Angol • Jelszó – a belépéshez van rá szűkség, rejtett szöveg, legalább 10 karakteres • Jelszó megerősítés – rejtett szöveg • Nem: legördülő menü, lehet: Férfi, Nő • Domináns kéz: legördülő menü, lehet: Bal, Jobb

	• Eszköz: legördülő menü, lehet: Laptop, PC, Táblagép, Okos telefon (az utolsó kettő le van tiltva, még nem működőképes) • Szesszió kód - ellenőrzött adatbevitel esetére, ha nem ellenőrzött maradhat üresen Emellett fontos, hogy a felhasználó elfogadja a Felhasználói Feltételeket. Amennyiben minden mező helyesen ki van töltve és a felhasználó elküldte az űrlapot, átirányítódik a bejelentkezés oldalra. Hiba esetén az alkalmazás jelez, hogy melyik mezőben, és milyen típusú hiba jelent meg.
Megszorítás	-

5.2. Táblázat - Bejelentkezési funkció

Bejelentkezési Funkció	
Leírás	Valós felhasználónév-jelszó kombinációval belépés a tanító oldalra. Tesztelés esetében, ha a bejelentkező személy átmegy a másodlagos ellenőrzésen is, megjeleníteni, hogy sikeresen bejelentkezett.
Prioritás	Nagyon fontos
Kiváltás	1. A felhasználó a főoldalra navigál. 2. A felhasználó nincs bejelentkezve, de olyan útvonalat próbál elérni, amit csak bejelentkezett felhasználók használhatnak. 3. A regisztrációs oldalon a felhasználó a *Vissza a bejelentkezéshez* linkre kattint. 4. A felhasználó kijelentkezik.
Funkcionális követelmény	A felhasználónak rendelkeznie kell egy valós fiókkal. Felhasználónév-jelszó párossal tud regisztrálni. A felhasználó amennyiben adatokat akar bevinni az adathalmaz bővítéséhez, a billentyűzési stílusát ellenőrző algoritmus is érvénybe lép, és amennyiben a mintája nem elég pontos, vissza kerül a főoldalra hibával. Sikeres bejelentkezés esetén: • Tanító módban: A felhasználó a tanítást lebonyolító oldalra lesz átirányítva.

	• Tesztelő módban: A felhasználó vissza lesz küldve a bejelentkezési oldalra egy sikeres belépést közlő üzenettel.
Megszorítás	Amennyiben a felhasználó teszteli a rendszert: A böngészőben be van kapcsolva a JavaScript.

5.3. Táblázat - Tanítási funkció

Tanítási Funkció	
Leírás	A felhasználó beírt adatainak és rögzített billentyűzési adatainak a lementése, amennyiben azok valósnak bizonyulnak. A ritmust lehetségesen elrontó karakterek letiltása vagy figyelmen kívül hagyása, helyzettől függően. Letiltott karakterek esetén hibaüzenet megjelenítése.
Prioritás	Nagyon fontos
Kiváltás	1. A felhasználó sikeresen bejelentkezett
Funkcionális követelmény	A felhasználó három mezőbe kell, hogy tudjon írni adatokat: 1. Felhasználónév – szöveg, legalább 8 karakter 2. Teljes név – szöveg, legalább 8 karakter 3. Tanítandó jelszó - legalább 8 karakteres szöveg, mely tartalmaz kis- és nagybetűt, számot és speciális karaktert Amennyiben a felhasználó a letiltott billentyűk közül valamelyiket lenyomja, a mező üresre állítódik, nullázódik a billentyűzési adat az adott mezőre, és megjelenik egy hibaüzenet 5 másodpercre, majd eltűnik. A letiltott billentyűk a következőek: *Backspace, Delete, Shift/Alt* lenyomása majd felengedése, közben leütött karakter nélkül, illetve *CapsLock* lenyomása kétszer, anélkül hogy közben karakterek is leütődtek volna. A *Tab, Enter, Ctrl* és navigáló billentyűk figyelmen kívül vannak hagyva billentyűleütési szempontból. Ha a felhasználó három másodpercen keresztül nem ír egy adott mezőbe, akkor az ezt követő karakter beírás lenullázza a

	mezőt, így megoldva azt, hogy a felhasználónak, ha elterelődik a figyelme, ne romoljon az adat. Sikeres adatbevitel esetén az oldalon megjelenítődik, hogy egyel több minta van leadva, a mezők újra állítódnak, és a felhasználó beviheti a következő adatot,
Megszorítás	1. A böngészőben be van kapcsolva a JavaScript.

5.4. Táblázat - Jelszó újraállítási funkció

Jelszó Újraállítási Funkció	
Leírás	A felhasználó az e-mail címét megadva egy link által újra tudja állítani a bejelentkező jelszavát.
Prioritás	Közepesen fontos
Kiváltás	1. A bejelentkezés oldalon az *elfelejtett jelszó* linkre kattintva.
Funkcionális követelmény	A felhasználónak kell rendelkeznie egy már meglévő fiókkal, és a fiókhoz tartozó e-mail címnek valódinak kell lennie. Ez után az adott e-mail címre elküldődik egy link, amit követve a felhasználó újra be tudja állítani a jelszavát.
Megszorítás	1. A böngészőben be van kapcsolva a JavaScript.

5.5. Táblázat - Folyamat megtekintési funkció

Folyamat Megtekintési Funkció	
Leírás	A felhasználó kell, hogy lássa, hány helyes mintát küldött be, mennyi kell egy szesszió befejezéséhez, és hány szessziót vitt végig.
Prioritás	Kevésbé fontos
Kiváltás	1. Sikeres bejelentkezés során
Funkcionális követelmény	A felhasználó láthatja számszerűen és egy fejlődésmutatón, hogy eddig hány adatot írt be. Minden sikeres leküldéssel növekszik ennek az értéke. Mikor a szessziót a felhasználó befejezte, egy üzenet jelenik meg, ami közli a sikeres kitöltést.
Megszorítás	1. A böngészőben be van kapcsolva a JavaScript.

5.6. Táblázat - Nyelvi funkció

Nyelvi Funkció	
Leírás	Angol és magyar nyelvű felület biztosítása.
Prioritás	Kevésbé fontos
Kiváltás	1. Az oldal bal felső sarkában lévő legördülő listából kiválaszt a felhasználó egy nyelvet.
Funkcionális követelmény	A nyelv váltás hatására az adott oldalon, és minden lapon, ahova az aktuális oldalról navigálunk, a nyelv megváltozik aszerint, hogy melyiket választotta a felhasználó.
Megszorítás	-

5.7. Táblázat - Segítői funkció

Segítői Funkció	
Leírás	A választott nyelven visszaküldött üzenet érvénytelen adatok esetén. Leírása a kísérletnek, a letiltott és ignorált karaktereknek, valamint az egyéb lehetséges félreértések tisztázása, mind például a tanító jelszó és a bejelentkezési jelszó közti különbség. Megjelenítése tanító módban a beírandó adatoknak.
Prioritás	Közepesen fontos
Kiváltás	1. A felhasználó a regisztrációs vagy tanító oldalra navigál.
Funkcionális követelmény	Útmutatót adni arról, hogy miket kell tegyen a felhasználó, mik a lehetőségei és megszorításai.
Megszorítás	1. A böngészőben be van kapcsolva a JavaScript.

A felhasználói eset diagram itt látható:

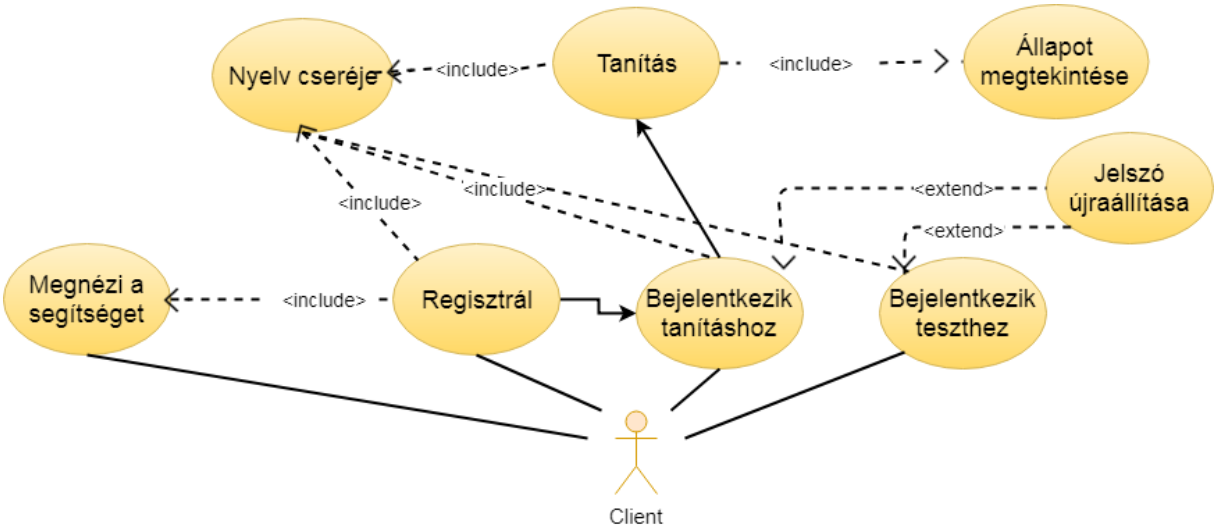

5.1. ábra - A felhasználó esetdiagramja

5.1.5 Nem funkcionális követelmények

5.1.5.1 Skálázhatóság és továbbfejleszthetőség

Az alkalmazás legyen skálázható, és könnyen továbbfejleszthető. Ajánlott az MVC tervezési mintát alkalmazni.

5.1.5.2 Karbantarthatóság

A bekövetkezett hibák legyenek naplózva a könnyű karbantartás végett.

5.1.5.3 Nyelvi követelmények

Az oldal több nyelven is megírható, de minimálisan angol nyelven legyen megírva. Ajánlott a Laravel lokalizációs módszerét használva nyelvi fájlokban tárolni a megírt szöveget, a későbbi többnyelvűsítés érdekében.

5.1.6 Interfész követelmények

5.1.6.1 Felhasználói interfész

A felhasználói interfész HTML-ben készüljön, böngészőből lehessen elérni. Ajánlott a HTML5 dokumentum típus, valamint Bootstrap 4.0 vagy annál újabb verzió, hogy könnyedén ki lehessen alakítani egy esztétikus felhasználói felületet. Emellett a Bootstrap segítségével

könnyedén tudunk egy olyan nézetet létre hozni, melynek formája és elrendezése a használt eszköz kijelzőjétől függően változik

A felület vázlata a következőképpen néz ki:

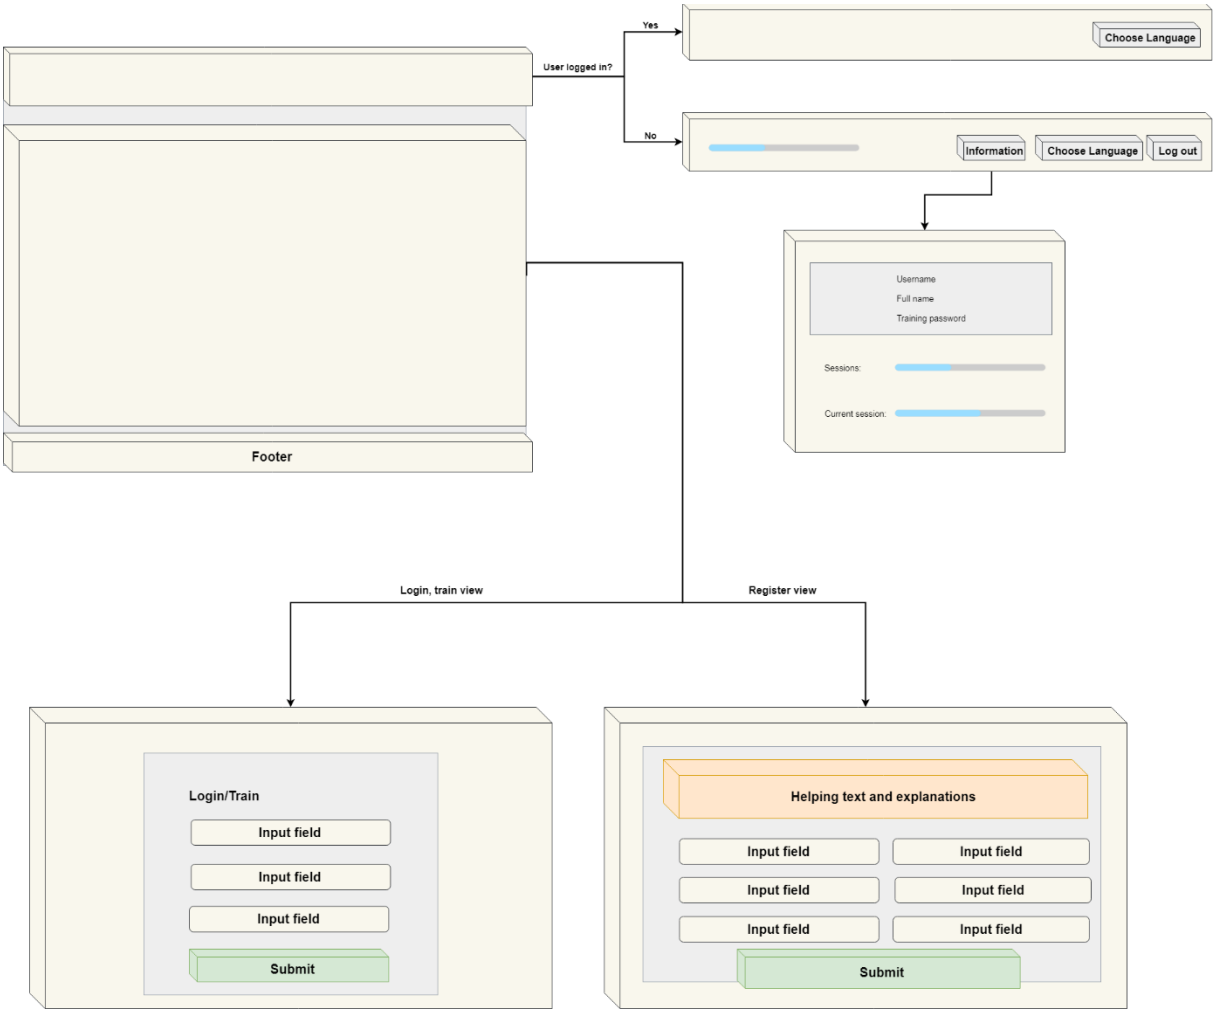

6. Részletes tervezés

6.1 Felhasznált technológiák

6.1.1 Adattárolás Firebaseben

A felhasználói és kísérleti adatok tárolására a Firebase valós idejű NoSQL adatbázisára esett a választásunk. Ennek fő okai közé sorolható a nagyobb mennyiségű adatok gyors kezelése valamint a tulajdonsága, hogy a PHP asszociatív tömbjeit képes egyben feltölteni és átalakítani őket JSON formátumba, ez által nincs szűkség külön konverzióra.

Direkt Laravel támogatást a Firebase nem nyújt, ezért egy külön modul segítségével oldottuk ezt meg, amit GitHub-on publikáltak. Miután hozzáadtuk a Laravel projektünkhöz az adott modult, egy Firebase által generált kulcs JSON file segítségével bárhol le tudtuk kérni az adatbázis referenciát. Miután a referenciát megkaptuk, a következő műveleteket lehet végre hajtani:

- getReference(útvonal)
  - Visszatérít az adott útvonalra egy hivatkozást.
- orderByChild(csomópont neve).
  - Az adott csomópont szerint fogja rendezni a lekért adatokat, amennyiben a csomópont létezik.
- equalTo(érték)
  - Amennyiben egy adott érték szerint már rendezve van az orderByChild tagfüggvény által a lekérendő érték, ez a függvény csak azokat a csomópontokat kéri le, amelyek egyenlők a megadott értékkel.
- getValue()
  - Visszatéríti a kért csomópontokat.
- set(érték)
  - Beállítja az adott referenciára a megadott értéket. Ha egy asszociatív tömböt adunk meg akkor az elemek egymás alatt, hierarchikusan fognak elhelyezkedni.

A következőkben néhány példát láthatunk az itt megemlített függvények működésére:

```
$db = $this->getFirebaseDatabaseReference();
$firebase_query = $db
    ->getReference( path: 'users/')
    ->orderByChild( path: 'username')
    ->equalTo($request->get( key: 'username'))->getValue();
$firebase_user_info = array_pop($firebase_query);
```

6.1. ábra - Firebase, felhasználó lekérdezése

A fenti ábrán először lekérjük az adatbázis referenciát, majd a *getReference* tagfüggvénnyel a csomópont referenciát. Ezután a felhasználónév („*username”*) szerint rendezzük a csomópontokat, és azt a csomópontot térítsük vissza, amelyik megegyezik (*equalTo*) a kérésben szereplő felhasználónévvel.

```
$db = $this->getFirebaseDatabaseReference();
$db->getReference( path: 'users/' . $user_data['username'])
    ->set($user_data);
```

6.2. ábra - Firebase, felhasználó regisztrálása

Az ábrán látható, ahogyan beállítjuk, hogy hova akarjuk elhelyezni a csomópontunkat, és utána megadjuk az adatot, amit fel szeretnénk tölteni. Érdemes megjegyezni, hogy a getReference fügvény paraméterében minden „/” jellel elválasztott szöveg egy új csomópont lesz.

A Firebase adatbázisban eltárolt csomópontoknak a következő a struktúrája:

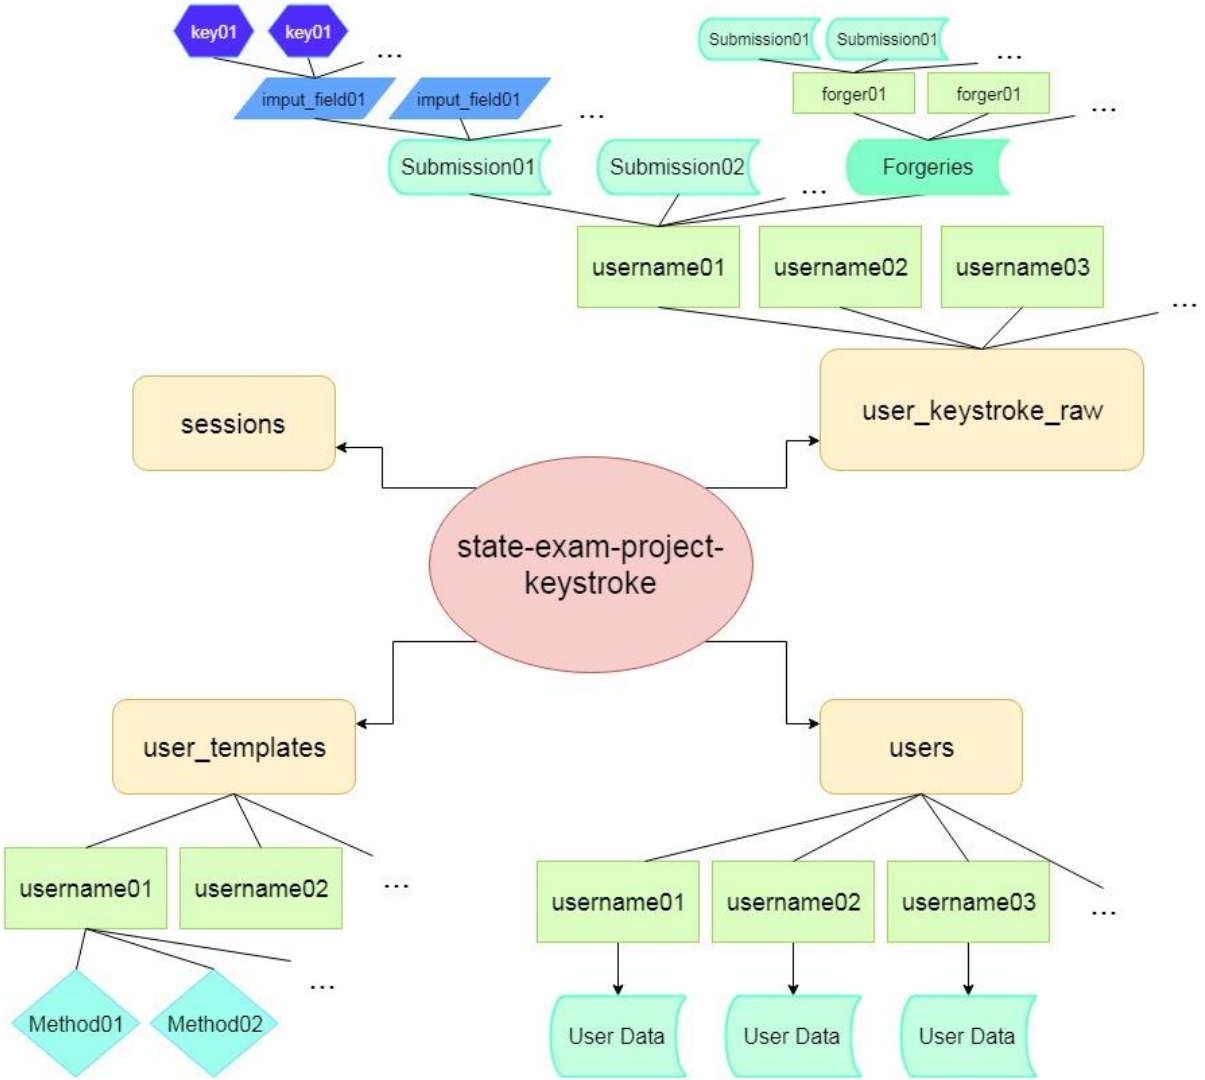

Magyarázat: Az egész adatbázis egy csomópont alatt helyezkedik el, ami a *state-exam-project-keystroke*. Ez alatt a következő csomópontok helyezkednek el:

1. *sessions* – a felügyelt tanításokhoz tartozó szesszió kódokat itt tároljuk
2. *user_keystroke_raw* – itt találhatóak a felhasználók nyers billentyűzési adatai, a következőképpen:

2.1. *username(s)* – a felhasználónév alapján lehet megtalálni valakinek az adatait
2.1.1. *timestamp(s)* – egy két részből álló azonosítója egy adott beküldésnek, az első része a beírás kezdeti dátumát, míg a második az aktuális időbélyeget tartalmazza
2.1.1.1. *input_field(s)* – az adott beküldés során kapott mezőket számokkal jelöltük, ahol 0 a felhasználónév, 1 a teljes név és 2 a tanítandó jelszó
2.1.1.1.1. *keystroke(s)* – egy bemeneti mezőben leütött billentyű, aminek két értéke van: egy leütési és egy felengedési időbélyeg
2.1.2. *forgeries* – a felhasználón végzett utánzások száma
2.1.2.1. *username(s)* – az utánzó vagy utánzók neve, ez alatt ugyanolyan időbélyegek vannak, mint a 2.1. alatt
3. *user_templates* – a felhasználók mintái, különböző algoritmusok által
3.1. *username(s)* - a felhasználónév alapján lehet megtalálni valakinek a mintáit
3.1.1. *algorithm(s)* – az algoritmus neve, amelyik által készült a minta
3.1.1.1. *pattern* – a minta, ami általában pár vektorból áll
3.1.1.2. *threshold* – a küszöbérték az adott felhasználóra
4. *users* – a felhasználók adatai, amiket a regisztrációnál adtak meg
4.1. *username(s)* - a felhasználónév alapján lehet megtalálni valakit
4.1.1. *device* – a felhasználó által választott eszköz
4.1.2. *email* – a felhasználó e-mail címe
4.1.3. *forgeries* – a utánzások száma
4.1.3.1. *username(s)* – a utánzók nevei
4.1.3.1.1. *number_of_samples* – az aktuális utánzó által leadott minták száma
4.1.4. *full_name* – a felhasználó teljes neve
4.1.5. *input_lengths* – a beírt karakterek hossza, mezőnként
4.1.5.1. *input* – a mező számmal jelölve, mint a 2.1.1.1. csomópontnál, az adott mezőbe beírt karakterek hosszát tartalmazza
4.1.6. *number_of_samples* – a felhasználó által beadott minták száma
4.1.7. *password_hash* – a bejelentkezéshez használt jelszó titkosítva
4.1.8. *training_password* – a tanuló jelszó, amit a felhasználó ír be több alkalommal
4.1.9. *user_age* – a felhasználó életkora
4.1.10. *user_gender* – a felhasználó neme
4.1.11. *user_nationality* – a felhasználó nemzetisége
4.1.12. *username* – a felhasználónév

6.2 Architektúra

Az alkalmazás architektúrája két fő komponensből tevődik össze:

- Kliens rész
  - A kliens által látható, publikus rész
  - Itt található a JavaScriptben megírt gyűjtő is
- Szerver rész

- Itt megy végbe a szerver oldali hitelesítés, valamint az adatok tárolása

A következő diagramon látható a rendszer architektúrája:

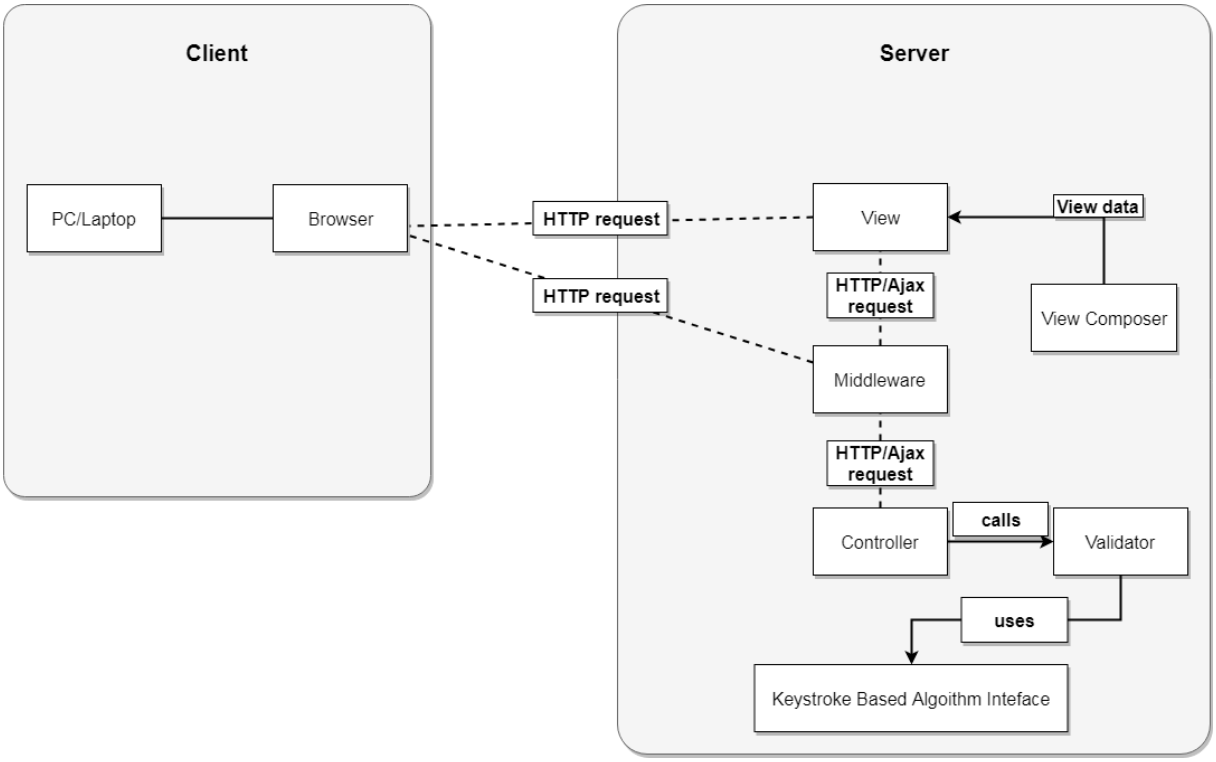

6.3 A rendszer tervezése és bemutatása

A rendszer Laravel 5.5 keretrendszerben készült, és követi az MVC tervezési mintát. Az osztályokat, vagy saját kezűleg hoztuk létre, vagy a Laravel parancsainak segítségével.

6.3.1 A kontroller rész

A Laravel keretrendszer által minden oldalhoz saját kontrollert készíthetünk, ami felelős a háttérben elvégzett logikáért. A kontrollerek függvényeket tartalmaznak, melyek a hozzájuk rendelt webes útvonal felkeresése esetén hívódnak meg. Ennek ellenére a kontroller nem minden esetben hívódik meg az URL beütése után, ha az útvonalra egy Middleware van csatolva. A Middleware-ek a kontroller előtt lépnek érvénybe, és képesek átirányítani a felhasználót egy másik URL-re még azelőtt, hogy elérnék az eredetileg kitűzött kontrollert. A következő állapotdiagram szemlélteti a felhasználó lehetséges eseteit az oldalon való navigálásnál.

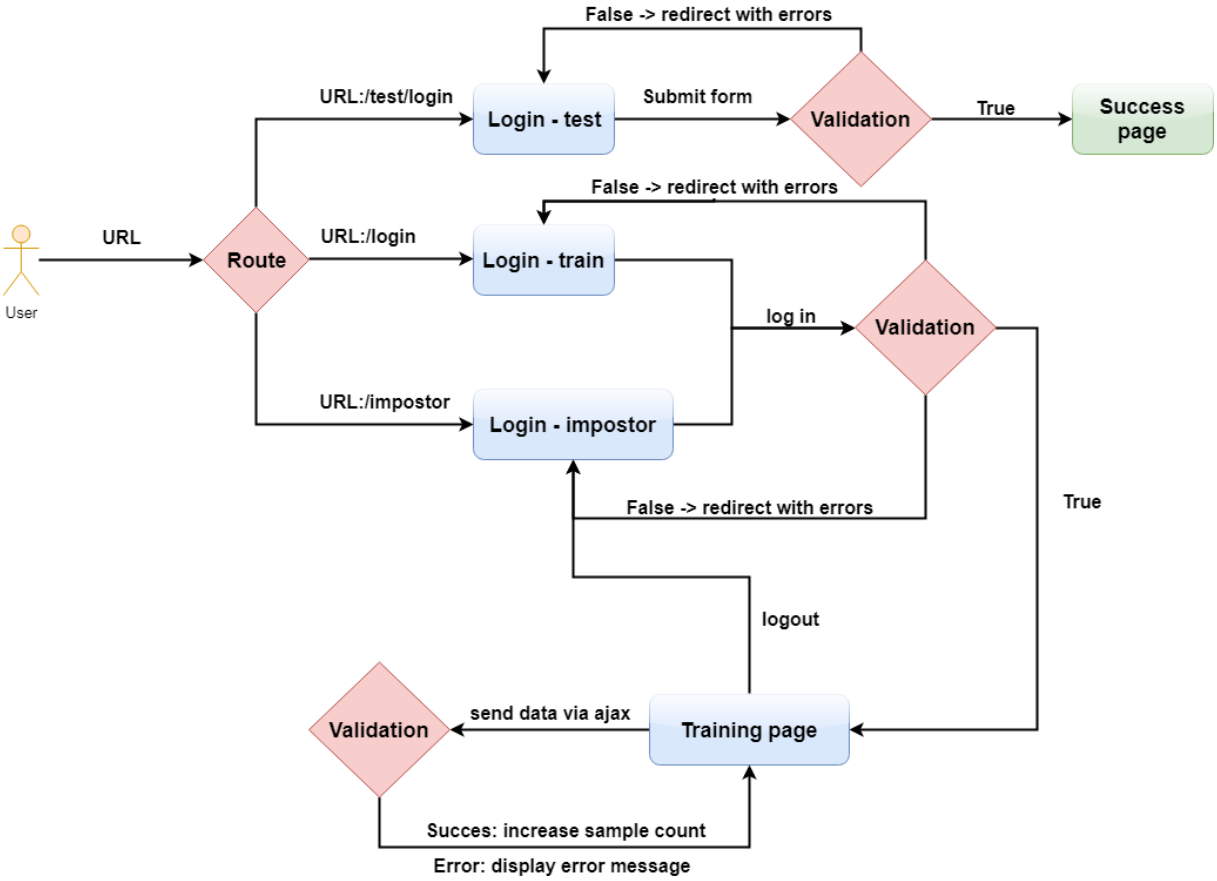

6.3.2 A modell rész

A modell részét a mi esetünkben a bárhol lekérhető adatbázis kapcsolat a Firebase-el helyettesíti.

6.3.3 A nézet (view) rész

A nézetek azok az erőforrások, melyek megjelenítődnek a felhasználó számára. Laravel esetében támogatva vannak az úgynevezett *blade* sablonok, amikkel könnyedén tudunk bonyolult logikát bevinni nézetünkbe. A nézethez néhány adat még a megjelenítés előtt hozzá kell, hogy rendelődjön, amiket a *View Composerek* segítségével oldottunk meg. Az nézetek elkészítéséhez Bootstrap 4.0 volt használva design szempontjából. Emellett a nézeteknél a többnyelvűsítés érdekében nyelvi változók vannak jelen statikus szövegek helyett

A következőkben látható néhány kép az elkészített nézetekről:

6.3. ábra - Bejelentkezési nézet

6.4. ábra - Tanítási nézet

6.4 Ajax hívások bemutatása

A kliens oldalon a tanításnál aszinkron hívással küldjük el a szervernek az űrlap tartalmát és a billentyűzési időket. Ehhez a JQuery könyvtár *post* metódusát használtuk. Az adatok megérkeznek egy kontroller függvényéhez, és amennyiben valóban Ajax hívás történt a függvény elvégzi a feldolgozást és vissza küldi az eddig összegyűjtött minták számát. Ezt a fogadó szkript feldolgozza, és megjeleníti a változásokat az oldalon.

6.5 Adatok mozgása

A teljes adatmozgás az oldalon a következő diagramon látható:

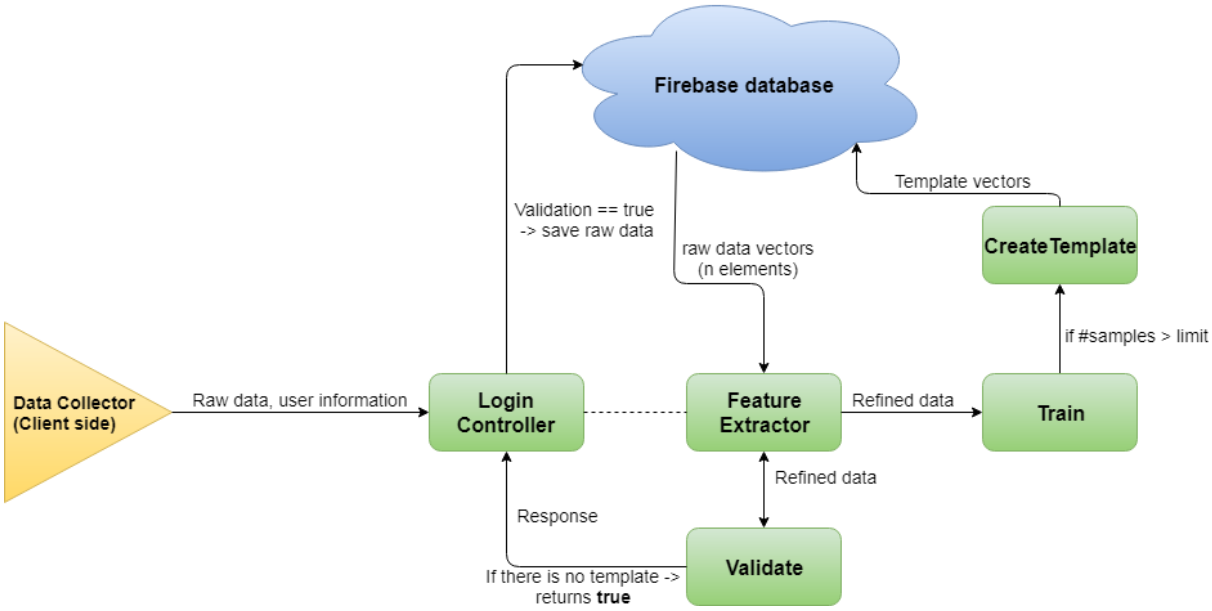

6.5. ábra - Adatok mozgása a rendszeren belül

7. Gyűjtő üzembe helyezése és kísérleti eredmények

7.1 Gyűjtő üzembe helyezése

Az alkalmazás a kliens részéről nem igényel semmiféle üzembe helyezést. A kliensnek egy böngészővel, amiben engedélyezve van a JavaScript és internetkapcsolattal kell rendelkeznie.

Szerver oldalon egy PHP 7.2 vagy újabb verzióra van szűkség, valamint a *Composer* függőség kezelőre. Az üzemeléshez ajánlott az Apache web szerver használata

7.2 Felmerült problémák és megoldásaik

Az egyik felmerült probléma abból származott, hogy a Firebase harmadik fél által készített összekötő modulja *localhost-on* rendesen működött, de az Ubuntu alapú szerveren nullás érték feltöltése esetén hibát adott. Ezt úgy orvosoltuk, hogy az adatbázisban minden értéket karakterláncként tároltunk.

7.3 A begyűjtött adathalmaz

7.3.1 Felhasználóktól gyűjtött adathalmaz

A gyűjtés során az oldalra 73 felhasználó regisztrált, viszont ezek közül csak 56 adott le adatokat. Minden regisztrált felhasználó a tanító felületen kellett beírja a felhasználónevét, valós nevét és az általa választott tanítandó jelszavat. Amennyiben valamelyik adatot elfelejteti, az *Információ* linkre kattintva képes megtekinteni minden bevitelt igénylő információt. A tanítandó jelszó bevezetése biztonsági és kényelmi megfontolásból történt, mivel a valós jelszó elfelejtése esetén azt újra be kéne állítani, ami elrontaná a kísérletet. Amennyiben a valós jelszavat nem titkosítva tárolnánk, szerver oldalon megoldható lenne a megjelenítése, de könnyen feltörhető lenne a felhasználók fiókja.

A gyűjtés alatt szessziónként 25 adatot kellett bevigyen minden felhasználó, és 43 személynek sikerült kettő, vagy több szessziót bevinnie. Eddig 3628 begépelt felhasználónév, jelszó, valamint teljes név időbélyegekből álló mintája van az adathalmazunkban (összesen 10884), amibe nem számoltuk bele azon felhasználók mintáit, akik 50-nél kevesebbet adtak le. A kinyert adatmennyiségek eloszlása a következő hisztogramon látható:

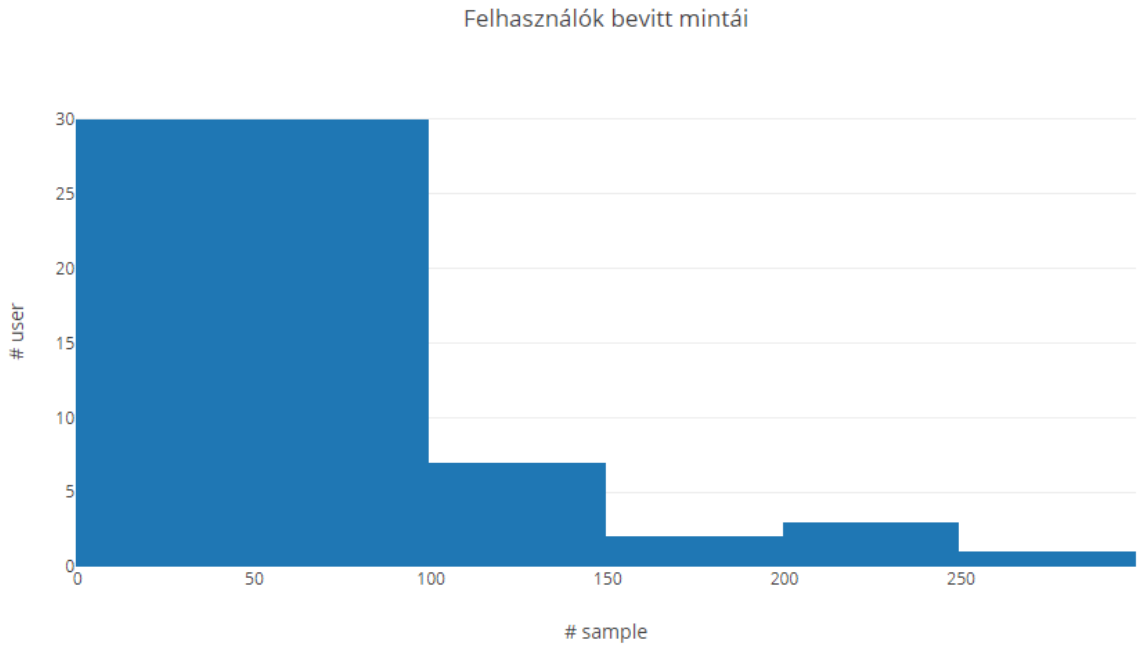

7.1. ábra - A felhasználók bevitt mintái

Bár szerver oldalon ellenőrizve vannak a bevitt adatok, de a leütött karaktereket nem lehet egy általános mintához kötni, mert a lenyomott karakterek száma személyenként változhat. Erre példa a *Shift* és *CapsLock* közötti különbség: Mikor nagybetűt akarunk írni, a *Shift* egy karakternek számít, aminek leütési ideje a betű előtt, és felengedési ideje a betű után van időrendi sorrendben. Ezzel ellentétben a *CapsLock* leütése és felengedése nagybetűs módra váltáshoz egy karakternek számít, míg a vissza váltás kisbetűre még egynek. Így az első megoldással két karakterünk lesz, míg a másodikkal három.

A beírt adatok első tíz mintája elvetődik, ha a felhasználó több mint négy nem ugyanolyan hosszúságú karaktersort írt le. A tizedik minta bevitelénél szerver oldalon egy ellenőrzés megy végbe: megkeressük a leggyakrabban megjelenő hosszúságokat mind a három mezőre, majd megnézzük, hány meglévő bevitelre érvényes az, hogy mindhárom bemenet ezekkel a hosszúságokkal rendelkezzen. Amennyiben hat és tíz közötti az elfogadott bevitelek száma, a visszautasítottak törlésre kerülnek, és a felhasználó értesül erről az által, hogy csökken a mintáinak a száma a felhasználói felületen is. Tíz helyes minta a felhasználó profiljához hozzárendelődik a három bemenetnek a hossza, és minden ezt követő bevitelt ezek alapján ellenőrizünk, ez által biztosítva az elkövetkező adatok helyességét.

7.3.2 Imposztoroktól gyűjtött adathalmaz

Miután elég aktív felhasználó regisztrált, nekifogtunk az imposztor adatok gyűjtésének. Az alkalmazáson belül létre hoztunk egy új útvonalat (Route-ot), amit csak azok érhetnek el, akikkel megosztjuk ezt. Itt a résztvevő beléphet a felhasználójával, illetve, amennyiben nem rendelkezik fiókkal az oldalon, vagy elfelejtette adatait, beléphet vendégfelhasználóként is.

A valós felhasználóktól való adat gyűjtéséhez hasonló felületen történik az utánzó felhasználók belépéseinek gyűjtése is. Egyetlen különbség, hogy egy más felhasználónak az adatait kell, hogy beírják, és ezek megjelennek, a könnyítés érdekében, a bemeneti mezőkben is helykitöltőként.

Az előbb említett valós adatok gyűjtésénél szó esett a *CapsLock* és *Shift* között lévő problémáról. Az imposztor adatok gyűjtésénél emiatt az eltérés miatt a begyűjtött 43 utánzásból, amiből minden felhasználót legalább egy szesszióban utánoztak (*1 szesszió = 25 minta*), csupán 27 felhasználónak volt elfogadható az utánzása a különböző karakter leütési hosszok miatt, a többi minta kísérleti szempontból selejtnek minősül. Emiatt 675 mintát tudtunk gyűjteni az imposztoroktól, minden mezőre (összesen 2025 minta).

A rendszer ennél a gyűjtésnél mindig olyan felhasználót adott az éppen belépőnek, amelynek még nincs, vagy a lehető legkevesebb számú utánzása van. A közeljövőben tervezzük a fentebb említett hibát kijavítani a *CapsLock* és *Shift* karakterek figyelmen kívül hagyásával.

7.4 Kísérleti eredmények

A kísérleti adathalmaz, az előző szekcióban tárgyalt okok miatt, 24 felhasználóból áll. Minden felhasználó 50 adattal rendelkezik, amiből 30 tanításra, és 20 tesztelésre van felhasználva. Emellett 25 utánzás is hozzá van rendelve minden felhasználóhoz, melyek segítségével tudunk egyenlő hibaarányt számolni.

A kísérletek során sikerült egy olyan algoritmushoz jutni, mely 2.8% EER-e rendelkezik. A próbálkozások során teszteket végeztünk a Manhattan Scaled, Mahalanobis, valamint egy módosított Manhattan Scaled osztályozóval. A kísérletekből kiderült, hogy a mezők különbözősége ellenére nagyon hasonló egyenlő hibaarány értékeket adnak az eddig tesztelt osztályozók használatánál. A különböző mezők pontszámait átlagoló valamint szorzó fúziónak vetettük alá, melynek hatására a következő eredményeket értük el:

Az alábbiakban bemutatom a gyűjtött adathalmazon végzett tesztelési eredményeket. A teszteket a következő halmazokkal végeztem a saját gyűjtésből: a felhasználók első 30 mintája volt a tanító halmaz, a teszt halmazt a felhasználók utolsó 20 mintája, illetve az imposztor felhasználók 25 mintája. Összehasonlítás végett ugyanilyen felépítésű halmazt használtunk a GREYC adathalmazból. A saját halmazból 25, a GREYC halmazból 48 felhasználó mintáit használtuk, ezek teljesítették azokat a feltételeket, amelyre szükség volt a teszthez.

Két osztályozót használtunk a Manhattan scale (Manscale) és Modified Manhattan scale (ModManscale) osztályozókat.

A táblázatokban hiba értékként az EER értékeket tüntettük fel százalékban, ahol átlagot számoltunk, ott megadtuk a szórást is.

Az alábbi táblázat az átlag EER értékeket tartalmazza a különböző tesztesetekre. Az értékek megfelelnek a szakirodalomból ismert értékeknek.

Osztályozó	**GREYC adatbázis**		**Saját gyűjtés**		
	login név	jelszó	login név	jelszó	teljes név

Manscale	10.8% (9.4)	11.1% (9.5)	10.1% (8.7)	9.6% (9.2)	9.9% (7.8)
Modmanscale	11.7% (10.1)	11.5% (10.3)	10.8% (9.9)	9.9% (9.4)	10.4% (8.2)

Az alábbi táblázat a fúziós eredményeket tartalmazza, ahol az osztályozók kimeneti értékeit két fúziós szabállyal, az átlaggal és szorzással kombináltuk és így egy új score értéket kaptunk minden teszt esetre (login név, jelszó és teljes név bevitele).

Fúziós szabály	**Osztályozó**	**GREYC adatbázis**	**Saját gyűjtés**	
		login+jelszó	login+jelszó	login+jelszó+név
Átlag (mean rule)	Manscale	6.5% (8.4)	5.3% (6.0)	2.8% (3.7)
	ModManscale	6.4% (8.6)	5.2% (6.4)	4.7% (5.0)
Szorzat (product rule)	Manscale	6.9% (8.6)	5.7% (6.5)	4.1% (4.7)
	ModManscale	7.4% (8.8)	6.2% (6.8)	4.3% (4.3)

Látható, hogy a fúziós megoldás javít az eredményeken, Ugyanakkor a javulás nagyobb a saját halmazunkban, ahol kis mintaszámmal számítottuk az eredményt, így azt, hogy nagy mintaszámra is hasonlóan viselkedik a halmazunk csak további gyűjtés után fogjuk megtudni.

Kiszámoltuk a globális EER-t is a két osztályozóra, ebben az esteben minden felhasználó score értékeivel végeztünk egy EER számítást. Így pl. a login névre a Manscale esetében 11.7%, míg a ModManscale esetében 17.4% az EER. Az EER görbéket lásd az alábbi két ábrán.

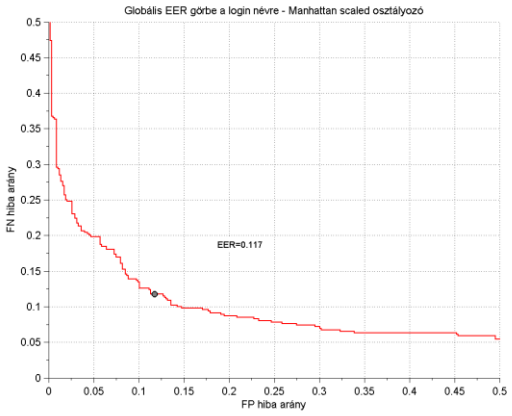

7.2. ábra - EER a Manhattam Scaled algoritmusra

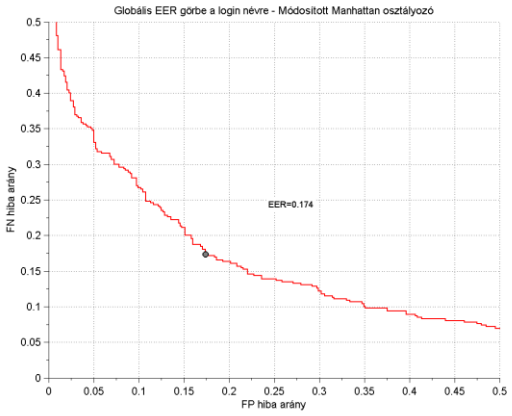

7.3. ábra - EER a Modifikált Manhattan Scaled algoritmusra

A score értékek eloszlását a Manscale osztályozó esetében a login névre az alábbi ábrán lehet megfigyelni. Látható, ahogy a valódi és imposztor felhasználó mintái összemosódnak.

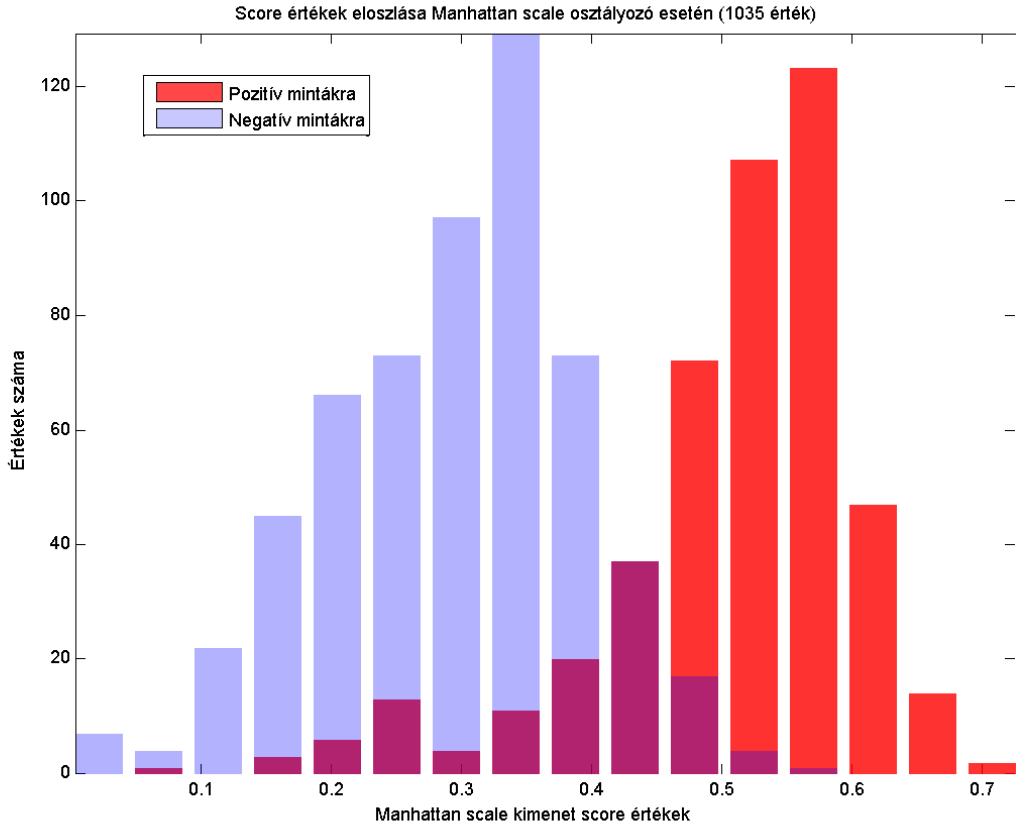

7.4. ábra - Score értékek eloszlása a Manhattan Scaled osztályozás során

8. Következtetések

8.1 Megvalósítások

Eddigi megvalósításaink közé tartozik egy Laravelben megírt webes alkalmazás, ami tartalmaz egy adatgyűjtő valamint egy azonosító (tesztelő) részt. Az adatgyűjtő komponens által képesek vagyunk egyidejűleg több felhasználótól billentyű leütési mintákat gyűjteni, valamint az utánzásokat is ugyanilyen módon az alkalmazással ki lehet nyerni. Emellett az éles tesztelés is lehetséges a teszt bejelentkezésért felelős URL-en keresztül.

Emellett sikerült gyűjteni 43 felhasználótól 50-nél több adatot, és 27 felhasználónak 25 vagy több utánzást is. Hogy az adatokat egyszerűen lehessen használni más programozási nyelvek által is, megírtunk egy átalakítót, ami a teljes JSON-ban tárolt adathalmazból a következő *csv* fájlokat generálja:

- *user_info.csv* – a felhasználók adatai
- *username_keystroke_data.csv* – a felhasználónevek nyers adataiból kinyert tulajdonságok
- *passwordTrain_keystroke_data.csv* – a tanítandó jelszavak nyers adataiból kinyert tulajdonságok
- *full_name_keystroke_data.csv* – a teljes nevek nyers adataiból kinyert tulajdonságok
- *username_keystroke_forgeries.csv* – a felhasználónevek utánzásainak nyers adataiból kinyert tulajdonságok
- *passwordTrain_keystroke_forgeries.csv* – a tanítandó jelszavak utánzásainak nyers adataiból kinyert tulajdonságok
- *full_name_keystroke_forgeries.csv* – a teljes nevek utánzásainak nyers adataiból kinyert tulajdonságok

Egy másik eredmény, amit a dolgozat alatt tárgyaltunk, a kísérletek elvégzése, melyeknek adatai hasznosak lehetnek későbbi kutatások számára. Emellett a kísérletek során egy olyan rendszert alkottunk, mely 2.8% EER-el rendelkezik felhasználók azonosítása terén.

8.2 Összehasonlítás hasonló rendszerekkel

Billentyűzés alapú másodlagos azonosító rendszerek már léteznek, és nagyobb kereskedelmi illetve bankozási alkalmazásoknál be vannak építve, viszont még nem található publikusan elérhető, magas pontosságú rendszer. Mi ennek a megalkotására törekedünk, miközben a lehető legjobb algoritmust keressük a rendszernek.

Más eddigi kísérletek során, például a Killourhy által kiadott cikkben [2], egy mezőre jobb eredményt értek el, viszont fúzió használatával három mezőre egy pontosabb azonosítót készítettünk.

Egy a miénkhez hasonló gyűjtésű adatbázis a Caeni egyetemen készült GREYC adatbázis [9]. Itt felhasználónév-jelszó párost gyűjtöttek felügyelet nélkül az egyetem hallgatóitól. A leírt felhasználói felület is hasonló funkcionalitásokkal rendelkezik a miénkhez, a cikk alapján. Fő különbségek a kísérletek végzésénél, és azok eredményeinél jelentkeznek.

8.3 További fejlesztési irányok

A rendszer még fejlesztést igényel könnyebb adat kinyerés, pontos utánzások, pontosabb osztályozó algoritmus és tanítási mintaszám szempontjából.

- Az adatok rögzítésénél a következőkben úgy fogjuk tárolni a *Shift* illetve *CapsLock* karakterek időit, hogy azok kivehetőek legyenek, az előzőekben említett okokból.
- Tervezzük a rendszert okos telefon és táblagép eszközökre is használhatóvá tenni. Jelenleg az oldal nézetei már úgy vannak tervezve, hogy jól kezelhető legyen az alkalmazás a kisebb kijelzővel rendelkező eszközöknél is.
- Az utánzások még pontosabbá tételéhez egy új ellenőrzőt adunk a tárolás előtt, mely a billentyűzési szempontból (több vagy kevesebb módosító leütés) nem megfelelő hosszúságú szövegeket nem menti el, és jelez az utánzónak. Emellett az oldalon megjelenítjük a felhasználó által leütött karaktereket is, arra az esetre, ha valami olyan kombinációt használt, ami nem egyértelmű.
- Az osztályozási algoritmus szempontjából a következőkben más algoritmusok felhasználásával próbálunk javítani az algoritmuson, ilyen lesz például a Mahalanobis távolságon alapuló algoritmus.
- Amennyiben sikerül több mintát gyűjteni, a tanító halmazt a túl távoli minták (outlier) kiszűrésével fogjuk felépíteni.
- A valós alkalmazás fejlesztése érdekében tervezzük megkeresni azt a minimális mintaszámot, amire a rendszer már elfogadható azonosítást nyújt.

9. Irodalomjegyzék

[1] Morales, A., Falanga, M., Fierrez, J., Sansone, C., & Ortega-Garcia, J. (2015, September). Keystroke dynamics recognition based on personal data: A comparative experimental evaluation implementing reproducible research. In *Biometrics Theory, Applications and Systems (BTAS), 2015 IEEE 7th International Conference on* (pp. 1-6). IEEE.

[2] Killourhy, K. S., & Maxion, R. A. (2009, June). Comparing anomaly-detection algorithms for keystroke dynamics. In *Dependable Systems & Networks, 2009. DSN'09. IEEE/IFIP international conference on* (pp. 125-134). IEEE.

[3] Teh, P. S., Teoh, A. B. J., & Yue, S. (2013). A survey of keystroke dynamics biometrics. The Scientific World Journal, 2013.

[4] Araújo, L. C., Sucupira, L. H., Lizarraga, M. G., Ling, L. L., & Yabu-Uti, J. B. T. (2005). User authentication through typing biometrics features. *IEEE transactions on signal processing*, *53*(2), 851-855.

[5] Ross, A. A., Nandakumar, K., & Jain, A. K. (2006). Handbook of multibiometrics (Vol. 6). Springer Science & Business Media.

[6] Tax, D. M. J. (2001). One-class classification: concept-learning in the absence of counter-examples [Ph. D. thesis]. Delft University of Technology, Stevinweg, The Netherlands.

[7] Araújo, L. C., Sucupira, L. H., Lizarraga, M. G., Ling, L. L., & Yabu-Uti, J. B. T. (2005). User authentication through typing biometrics features. IEEE transactions on signal processing, 53(2), 851-855.

[8] Zhong, Y., Deng, Y., & Jain, A. K. (2012, June). Keystroke dynamics for user authentication. In Computer Vision and Pattern Recognition Workshops (CVPRW), 2012 IEEE Computer Society Conference on (pp. 117-123). IEEE.

[9] Giot, R., El-Abed, M., & Rosenberger, C. (2012, July). Web-based benchmark for keystroke dynamics biometric systems: A statistical analysis. In Intelligent Information Hiding and Multimedia Signal Processing (IIH-MSP), 2012 Eighth International Conference on (pp. 11-15). IEEE.

[10] Fawcett, T. (2006). An introduction to ROC analysis. Pattern recognition letters, 27(8), 861-874.

[11] Li, S. Z., & Jain, A. (2015). Encyclopedia of biometrics. Springer Publishing Company, Incorporated.

10. Függelékek